作业 3 选项 2：使用神经网络进行昆虫分类

胡广理 PB24010500

2026-05-05

1 问题与建模

本实验选择选项 2。目标是利用昆虫的体长 x_1 与翼长 x_2 两个特征，将样本分类到 0、1、2 三个类别。训练集记为

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n}, \quad \mathbf{x}_i = (x_{i1}, x_{i2}) \in \mathbb{R}^2,\ y_i \in \{0, 1, 2\}.$$

神经网络输出三维 logit 向量 $z = f_\theta(\mathbf{x})$，再用 softmax 得到类别概率

$$p_k(\mathbf{x}) = \frac{e^{z_k}}{\sum_{j=0}^{2} e^{z_j}}.$$

训练目标为最小化交叉熵损失

$$L(\theta) = -\frac{1}{n} \sum_i \log p_{y_i}(\mathbf{x}_i).$$

分类规则为 $\hat{y} = \arg\max_k p_k(\mathbf{x})$。

为避免不同量纲影响训练，所有模型均只使用训练集估计均值与标准差，并对训练集、验证集、测试集做同一标准化变换。训练集内部按类别分层划分出 20% 作为验证集，用于早停和比较网络参数；测试集只在最终评价时使用。

2 算法实现

实现使用 `PyTorch`，运行环境为已有 conda 环境 `cupy`。为了考察网络参数影响，实验比较了线性 softmax 分类器、单隐层 MLP、不同激活函数以及带 L2 正则的双隐层 MLP。优化器使用 Adam，损失函数使用交叉熵。每种设置使用 5 个随机种子重复实验，报告平均值与标准差。

测试集按作业要求拆成两段评价：前 60 个样本来自训练数据的随机抽取，可观察模型对已知分布/近似已见样本的拟合能力；后 150 个样本不在训练集中，更能衡量模型对新昆虫数据的泛化能力。因此报告中更重视后 150 个样本的准确率。

3 数据可视化

从散点图可见，数据集 1 的三类样本分界较清晰；数据集 2 加入测量噪声后，同类样本更分散，类别边界附近的重叠更明显，分类难度更高。因此数据集 2 更需要适当的正则化和验证集早停，以降低过拟合风险。

4 参数对比结果

下表中 `seen60` 表示测试集前 60 个样本准确率，`new150` 表示后 150 个新样本准确率，`all210` 表示全部测试样本准确率。

dataset	config	seen60	new150	all210	epochs
dataset1_clean	mlp_16_tanh	0.987 ± 0.007	0.977 ± 0.017	0.980 ± 0.013	803
dataset1_clean	mlp_32_16_relu_l2	0.963 ± 0.036	0.949 ± 0.034	0.953 ± 0.034	473
dataset1_clean	mlp_16_8_relu_l2	0.950 ± 0.066	0.947 ± 0.034	0.948 ± 0.042	545

dataset	config	seen60	new150	all210	epochs
dataset1_clean	mlp_8_relu	0.933 ± 0.046	0.925 ± 0.044	0.928 ± 0.044	537
dataset1_clean	softmax_linear	0.863 ± 0.007	0.889 ± 0.004	0.882 ± 0.002	690
dataset2_noisy	mlp_16_8_relu_l2	0.897 ± 0.014	0.937 ± 0.029	0.926 ± 0.021	306
dataset2_noisy	mlp_16_tanh	0.880 ± 0.022	0.937 ± 0.004	0.921 ± 0.006	338
dataset2_noisy	mlp_32_16_relu_l2	0.890 ± 0.015	0.933 ± 0.024	0.921 ± 0.016	479
dataset2_noisy	mlp_8_relu	0.883 ± 0.017	0.912 ± 0.028	0.904 ± 0.016	446
dataset2_noisy	softmax_linear	0.900 ± 0.012	0.893 ± 0.007	0.895 ± 0.003	733

数据集 1 最佳模型为 `mlp_16_tanh`，后 150 个新样本准确率为 **0.977 ± 0.017**，全部测试准确率为 **0.980 ± 0.013**。数据集 2 最佳模型为 `mlp_16_8_relu_l2`，后 150 个新样本准确率为 **0.937 ± 0.029**，全部测试准确率为 **0.926 ± 0.021**。

5 最佳模型分类边界

决策边界显示，神经网络能够学习到非线性的类别分割曲线。线性模型只能给出直线边界，在类别形状较弯曲或噪声较强时表达能力不足；双隐层 ReLU 网络可以形成更灵活的分段线性边界，但如果网络过大且缺少正则化，也可能把边界拉向个别噪声点。实验中带 L2 正则与早停的双隐层模型通常在新样本上更稳定。

6 训练过程

训练曲线表明，交叉熵损失快速下降后趋于稳定。验证集准确率没有继续提升时触发早停，可以减少后续迭代对训练集局部噪声的记忆。

7 影响因素分析

1. 网络结构：无隐层的 softmax 线性分类器表达能力最低；加入隐层后可以拟合非线性边界，通常提升新样本准确率。
2. 激活函数：ReLU 收敛较快，边界呈分段线性；tanh 边界更平滑，但在本数据规模下并不一定优于 ReLU。
3. 正则化：数据集 2 存在测量噪声，L2 正则与早停对泛化更重要。过大的网络若不约束，可能提高训练/前 60 样本表现，却降低后 150 个新样本准确率。
4. 数据噪声：数据集 2 相比数据集 1 的类别重叠更多，因此相同模型的准确率波动更明显。实际建模时应优先关注新样本准确率，而不是只看训练集或前 60 个样本。

8 结论

本实验完成了两组昆虫数据集上的神经网络分类。结果说明，仅用体长和翼长两个特征，MLP 已能较好区分三类昆虫；对于无额外噪声的数据集，简单 MLP 即可获得较高准确率；对于含噪声数据，带正则化的网络和早停机制更稳健。分段测试也说明，前 60 个样本不能完全代表泛化能力，后 150 个新样本的表现才是评价模型有效性的关键。

9 AI 使用说明

本报告和代码由本人在理解作业要求、确认数据格式和实验目标后，借助 AI 辅助整理实验流程、生成可复现实验脚本和报告初稿；最终内容经过人工检查，确保实验设置、结果解释和结论与实际运行输出一致。

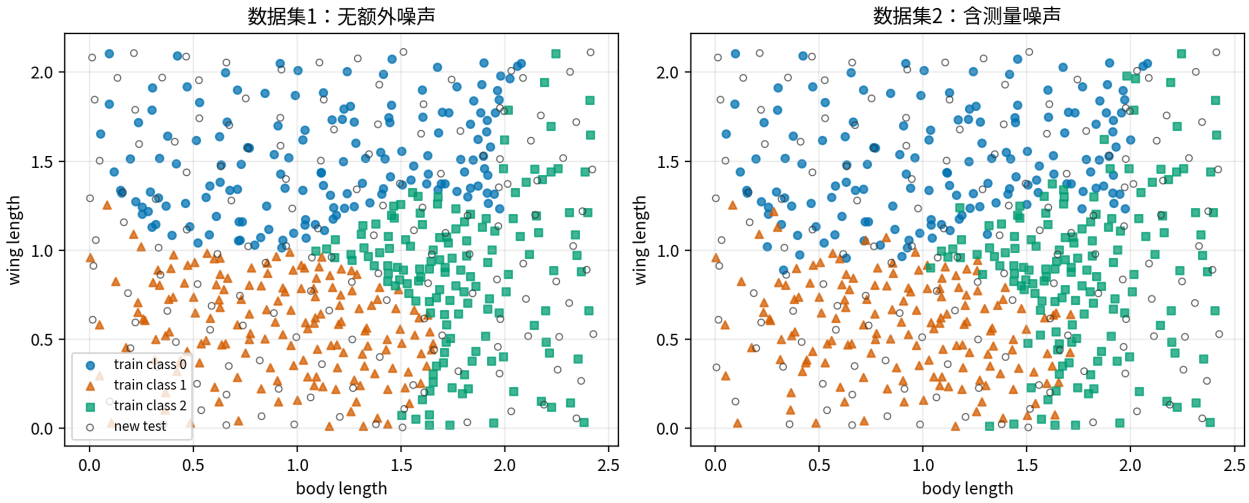

Figure 1: 两组数据的训练集与新测试样本分布

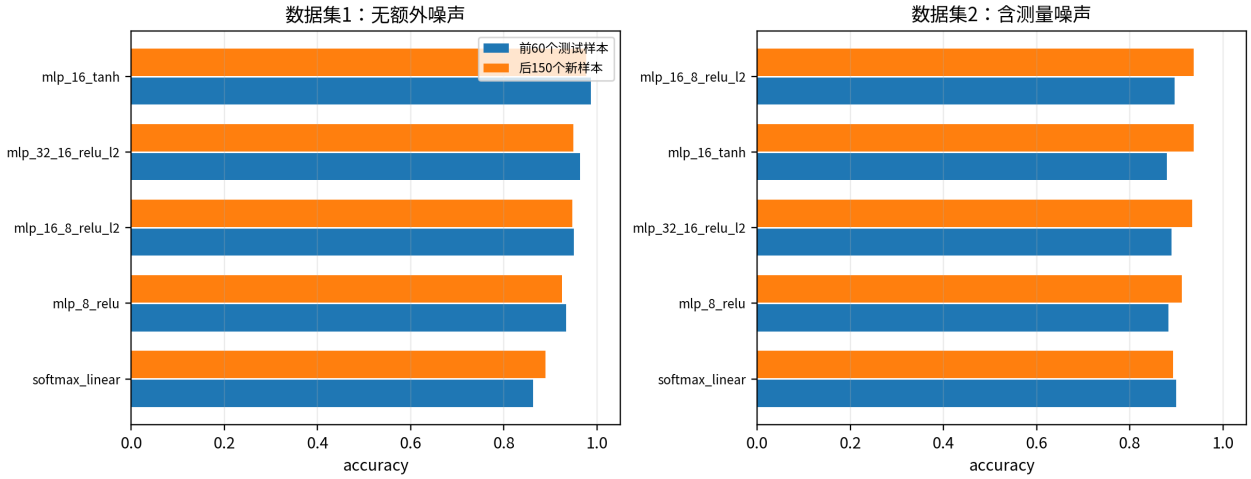

Figure 2: 不同网络参数对准确率的影响

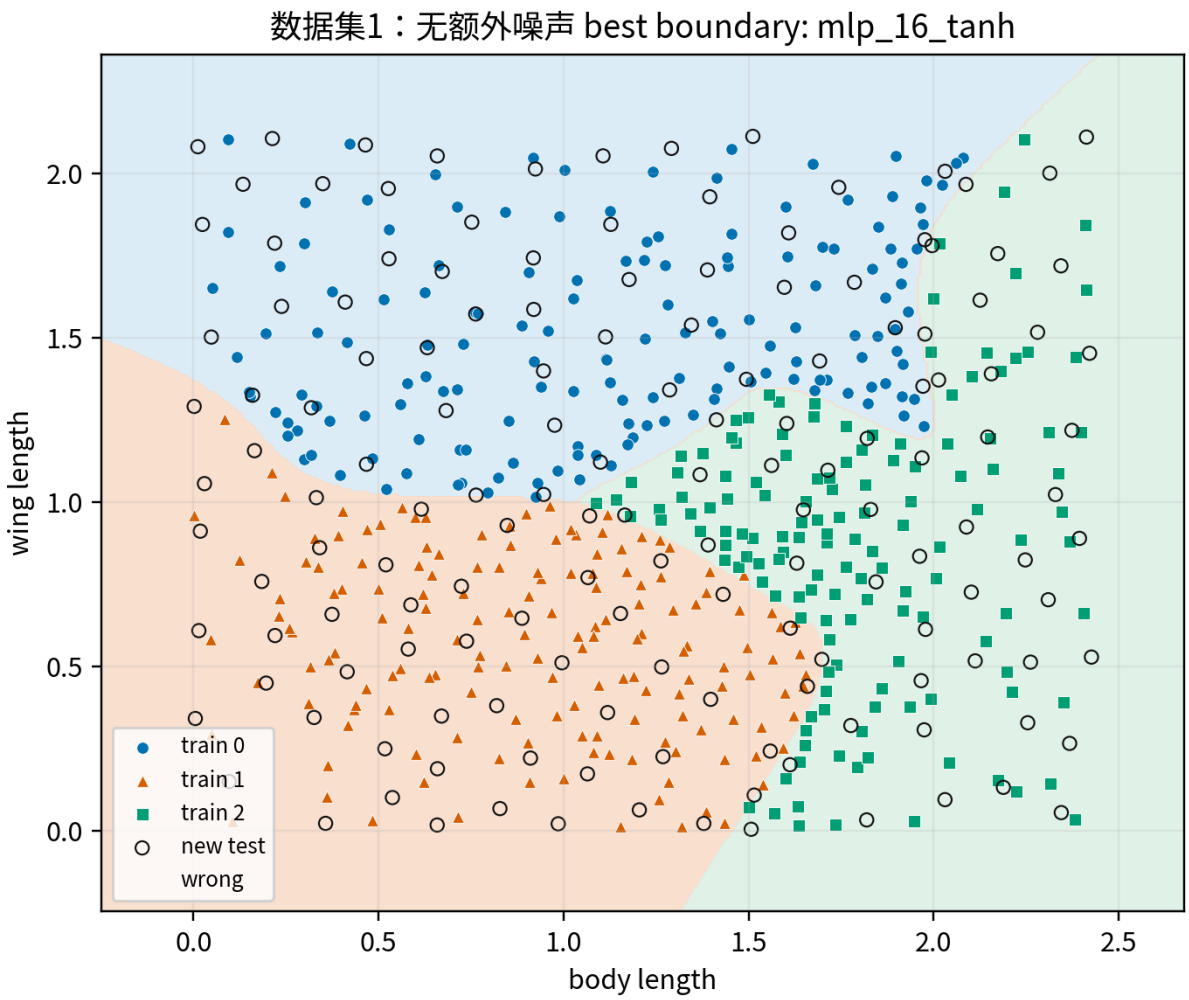

Figure 3: 数据集 1 最佳模型决策边界

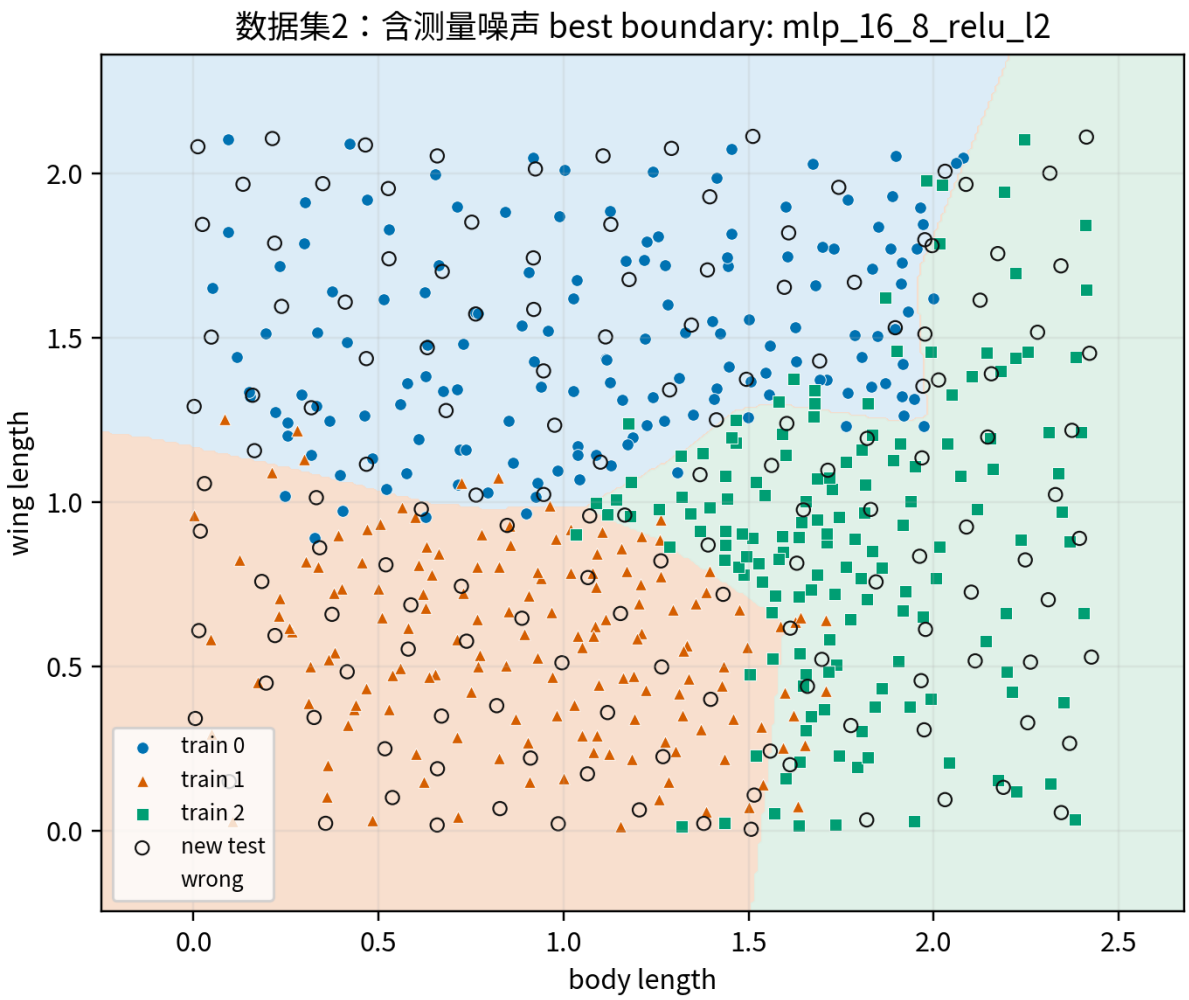

Figure 4: 数据集 2 最佳模型决策边界

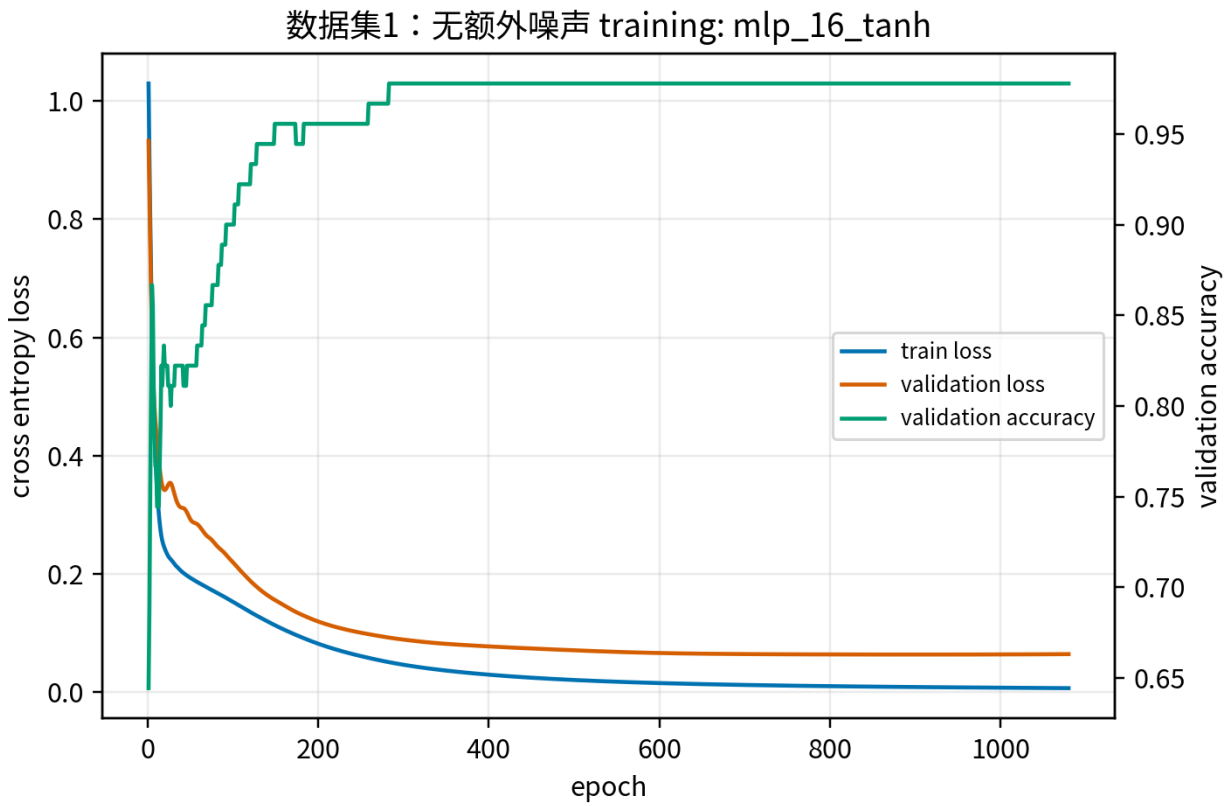

Figure 5: 数据集 1 最佳模型训练曲线

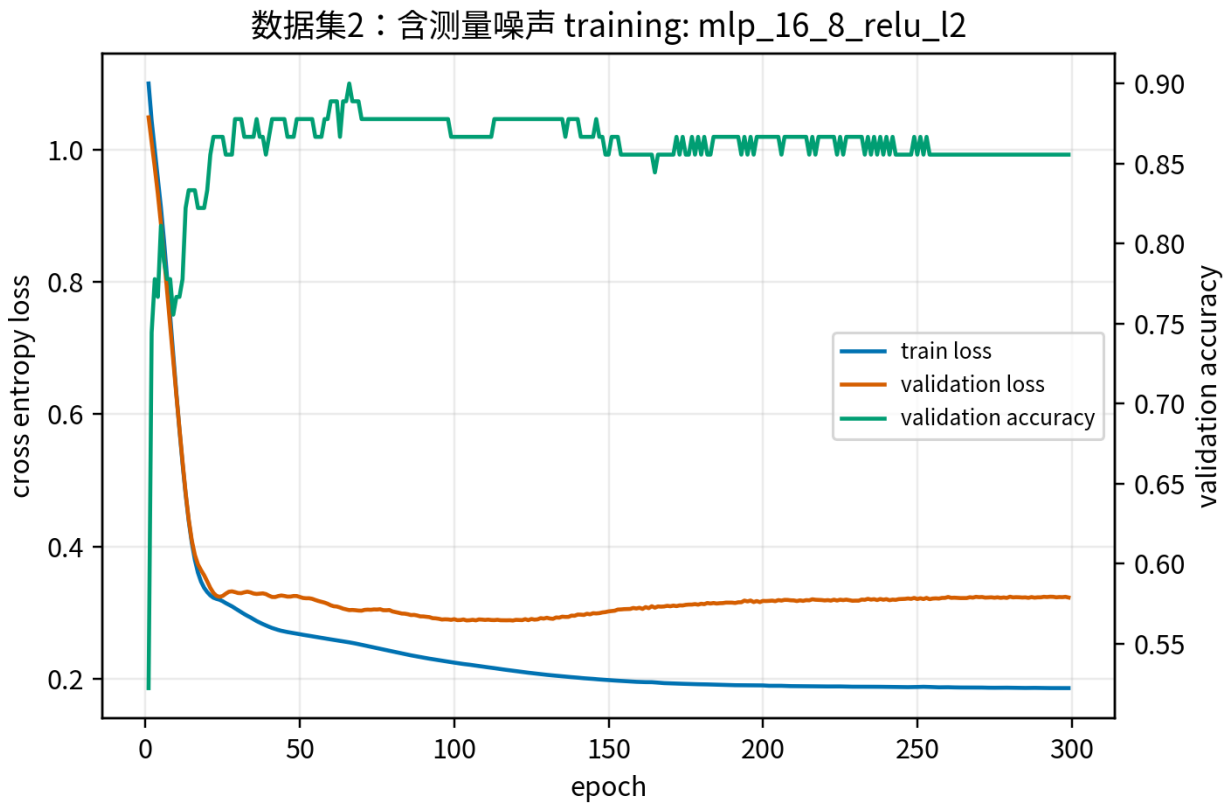

Figure 6: 数据集 2 最佳模型训练曲线